第四题：时间序列异常检测——数据理解

1. 我们到底在做什么？

本项目的目标是：

> 从大规模监控指标中自动发现异常时间序列。

简单来说，假设一个大型电商网站正在运行，系统中有：

- 前端服务（Frontend）
- 商品服务（Product Catalog）
- 购物车服务（Cart）
- 支付服务（Payment）
- 推荐服务（Recommendation）
- 广告服务（Ad）

以及运行这些服务的基础设施组件：

- 服务器（Node）
- 容器（Container）
- JVM（Java 虚拟机）
- Istio 服务网格

这些组件会持续产生监控数据，例如：

```
CPU 利用率
内存占用
GC 次数
请求量
响应时间
网络流量
```

项目要求自动找出：

```
哪些指标出现异常？
什么时候出现异常？
```

---

2. 数据集整体结构

数据目录：

```
metric/
├── 2022-03-20-cloudbed1
```

```
├── 2022-03-20-cloudbed2
├── 2022-03-20-cloudbed3
├── 2022-03-21-cloudbed1
├── 2022-03-21-cloudbed2
└── 2022-03-21-cloudbed3
```

共有：

```
2 天数据 × 3 个场景 = 6 个数据集
```

总大小：

```
约 3.5GB
```

---

3. 数据分为哪几类?

每个场景下都有：

```
metric/
├── service
├── node
├── container
├── jvm
└── istio
```

3.1 service

业务层指标，记录请求成功率、响应时间、请求数量等。

例如：

```
service,timestamp,rr,sr,mrt,count
adservice-grpc,1647716400,100.0,100.0,2.43,61
```

字段含义：

字段	含义
service	服务名称
timestamp	时间戳
rr	响应率

字段	含义
sr	成功率
mrt	平均响应时间
count	请求数

3.2 node

物理机或虚拟机指标。

例如：

```
timestamp,cmdb_id,kpi_name,value
1647792000,node-4,system.load.5,0.65
```

表示：

```
node-4 机器的 5 分钟平均负载 = 0.65
```

3.3 container

容器指标。

例如：

```
timestamp,cmdb_id,kpi_name,value
1647813600,node-5.paymentservice-
1,container_network_receive_packets_dropped.eth0,0.0
```

表示：

```
paymentservice 容器丢包数 = 0
```

3.4 jvm

Java 虚拟机指标。

例如：

```
timestamp,cmdb_id,kpi_name,value
1647828000,adservice.ts:8088,java_nio_BufferPool_TotalCapacity.direct,57343
```

表示：

```
广告服务 JVM Direct Buffer 容量 = 57343
```

3.5 istio

服务网格指标。

例如：

```
timestamp,cmdb_id,kpi_name,value
1647828000,istio-egressgateway-
xxx,istio_agent_startup_duration_seconds,40.8
```

表示：

```
Istio 组件启动耗时 = 40.8 秒
```

---

4. 什么是一条时间序列?

这是整个项目最重要的概念。

监控数据统一格式为：

```
timestamp,cmdb_id,kpi_name,value
```

其中：

```
cmdb_id + kpi_name
```

唯一确定一条时间序列。

例如：

```
(node-4, system.load.5)
```

形成：

```
时间     值
08:00   0.65
08:01   0.69
08:02   0.68
08:03   0.74
...
```

这就是一条时间序列。

---

5. 为什么老师说有 5000+ 序列?

一开始我们以为:

```
一个 CSV = 一条序列
```

后来发现不对。统计结果如下:

```
container : 5417
jvm       : 667
istio     : 2252
node      : 354
----------------
总计      : 8690
```

因此:

```
项目实际包含约 8690 条时间序列
```

远超老师要求的:

```
5000+
```

---

6. 采样频率是多少?

观察数据:

```
1647792000
1647792060
```

```
1647792120
1647792180
```

时间戳每次增加：

```
60 秒
```

因此：

```
采样频率 = 60 秒
```

与题目要求完全一致。

---

7. 一条序列有多长？

统计发现：

```
(node-4, system.load.5)
```

共有：

```
1440 个点
```

因为：

```
24 小时 × 60 分钟 = 1440
```

所以：

```
每条时间序列覆盖一天数据
```

---

8. 后续异常检测的对象是什么？

异常检测不是针对：

```
CSV 文件
```

而是针对：

```
(cmdb_id, kpi_name)
```

对应的时间序列。

例如：

```
(node-4, system.load.5)
```

或者：

```
(paymentservice-1, container_cpu_usage_seconds_total)
```

---

9. 我们后面要做什么？

整体流程：

```
HDFS
↓
Spark 读取数据
↓
构造 8690 条时间序列
↓
异常检测（IQR 等方法）
↓
发现异常时间点
↓
输出异常指标
```

最终目标：

```
找出哪些指标异常，以及异常发生的时间
```

而不是简单统计均值或画图。

---

10. 当前项目进度

已完成：

```
Hadoop 环境搭建        ✅
Spark 环境搭建         ✅
数据上传到 HDFS        ✅
数据理解               ✅
```

下一阶段：

```
Spark 读取 HDFS 数据
↓
构造时间序列
↓
实现异常检测算法
```