# 大数据分析技术项目（第四题）环境搭建

## 一、服务器信息

三台 CentOS 7 服务器：

| 节点 | IP | 主机名 |
| --- | --- | --- |
| Master | 10.176.62.206 | master |
| Worker1 | 10.176.62.207 | worker1 |
| Worker2 | 10.176.62.208 | worker2 |

每台服务器配置：

- CPU：8核
- 内存：16GB
- 磁盘：约100GB

---

## 二、已完成工作

### 1. 基础环境配置

已完成：

- 修改 hostname
- 配置 /etc/hosts
- 配置 SSH 免密登录
- Master、Worker1、Worker2 之间可直接 SSH 通信

---

### 2. JDK 部署

版本：

- OpenJDK 8 (Temurin 8u492)

安装路径：

bash /usr/local/jdk8

验证：

bash java –version

三台服务器均为：

text openjdk version "1.8.0_492"

---

## 3. Hadoop 部署

版本：

text Hadoop 3.3.6

安装路径：

bash /usr/local/hadoop

配置完成：

text core-site.xml hdfs-site.xml yarn-site.xml mapred-site.xml workers hadoop-env.sh

---

## 4. HDFS 集群部署

架构：

text master └── NameNode worker1 └── DataNode worker2 └── DataNode

副本数：

text dfs.replication = 2

验证成功：

bash hdfs dfsadmin -report

显示：

- 2个 DataNode 在线
- 状态正常（Normal）
- 总容量约100GB

---

## 5. YARN 集群部署

架构：

text master └── ResourceManager worker1 └── NodeManager worker2 └── NodeManager

验证：

bash jps

显示：

text ResourceManager NodeManager

均正常运行。

---

## 6. Spark 集群部署

版本：

text Spark 3.5.1

安装路径：

bash / usr/local/spark

架构：

text master └── Spark Master worker1 └── Spark Worker worker2 └── Spark Worker

验证：

bash spark-submit --version

三台机器均为：

text Spark 3.5.1 OpenJDK 8u492

---

### 7. Spark on YARN 测试

测试命令：

bash spark-submit \ --master yarn \ --class org.apache.spark.examples.JavaWordCount \ /usr/local/spark/examples/jars/spark-examples_2.12-3.5.1.jar \ hdfs://master:9000/spark-test/words.txt

输出：

text hello: 2 spark: 1 hadoop: 1

测试通过。

说明：

- Spark 能提交任务
- Spark 能读取 HDFS 数据
- Spark 能运行在 YARN 上
- 分布式计算正常

---

## 三、当前集群状态

Master：

text NameNode SecondaryNameNode ResourceManager Master

Worker1：

text DataNode NodeManager Worker

Worker2：

text DataNode NodeManager Worker

通过：

bash jps

可查看。

---

# 四、第四题后续开发建议

后续项目开发流程：

训练数据.xlsx ↓ 上传 HDFS ↓ Spark DataFrame 读取 ↓ 数据清洗 ↓ 特征工程 ↓ 异常检测 ↓ 结果分析 ↓ 可视化 ↓ 实验报告

---

# 五、重要注意事项

## 1. 不要再次执行 format

禁止执行：

bash hdfs namenode –format

原因：

会清空整个 HDFS 元数据。

---

## 2. 集群启动命令

若服务器重启：

启动 HDFS：

bash start–dfs.sh

启动 YARN：

bash start–yarn.sh

启动 Spark：

bash start–master.sh start–workers.sh

---

## 3. 集群关闭命令

bash stop–workers.sh stop–master.sh stop–yarn.sh stop–dfs.sh

---

## 4. 查看集群状态

bash jps

```
bash hdfs dfsadmin -report
```

---

### 5. HDFS 常用命令

上传：

```
bash hdfs dfs -put localfile /data/
```

查看：

```
bash hdfs dfs -ls /
```

读取：

```
bash hdfs dfs -cat file
```

删除：

```
bash hdfs dfs -rm file
```

---

## 六、结论

目前 Hadoop + HDFS + YARN + Spark 集群已全部部署完成并通过验证测试。

后续工作可直接进入第四题的数据处理与异常检测算法开发阶段。